

ВЫЯВЛЕНИЕ КОГНИТИВНОГО РАЗРЫВА В ОТЗЫВАХ:

**от классификации к анализу
противоречий**

ЦЕЛЬ

Разработать ml-модель для прогнозирования рейтинга и выявления когнитивного разрыва между текстом отзыва и оценкой

01

Сбор и предобработка
данных

02

Векторизация текста

03

Построение и сравнение
моделей

04

Анализ когнитивного
разрыва

СБОР ДАННЫХ: РЕЗУЛЬТАТ В ЦИФРАХ

0

**товаров без
рейтинга**

каждый
товар имеет
по крайней
мере 1 отзыв

18

признаков

подвергнутых
тематическим
группировкам

61к+

ОТЗЫВОВ

полный объем
данных на
момент
парсинга

1+ МЛН

СЛОВ

эквивалент 4
романов «Война и
мир». Объем,
который ml-модель
проанализирует за
несколько секунд

КОРЕЛЯЦИОННЫЙ АНАЛИЗ

Анализ выявил незначительную корреляцию цены и рейтинга - **цена не влияет на рейтинг**

Сильная связь между рейтингом товара и текстом отзыва. Длина текста отзыва не влияет на оценку.

Для покупателя главным источником являются отзывы других покупателей




РАСПРЕДЕЛЕНИЕ РЕЙТИНГОВ


86% отзывов из датасета — положительные

Тестирование балансировки классов
ухудшила качества на доминирующем
классе в тестовой выборке

В рамках исследовательской задачи было
принято решение сохранить исходное
распределение



Без балансировки



С балансировкой*

*наименьшее ухудшение из балансировки

ПРЕДОБРАБОТКА ТЕКСТА

clean &
tokenize

ΔΟ

Works as it claims. Could see the difference from the first day. Use it with Olay cleanser for best results

ПОСЛЕ

work claim could see
difference first day use olay
cleanser best result

visualize


лемматизации & векторизации (TF-IDF)



СРАВНЕНИЕ МОДЕЛЕЙ В КЛАССИФИКАЦИИ ТОНАЛЬНОСТЕЙ & ДЕМОНСТРАЦИЯ РЕЗУЛЬТАТОВ

*пример вывода результатов

```
1 Отзыв: "This product is absolutely amazing! I love it, my skin look
2 Предсказанная тональность: Положительный
3 Вероятность принадлежности к классу: 0.649
4 Отзыв: "Terrible product, complete waste of money. It broke me out
5 Предсказанная тональность: Отрицательный
6 Вероятность принадлежности к классу: 0.019
```




Для выявления наиболее эффективной модели были рассмотрены методы LR NB SVM

Обученная модель получает отзыв на вход и выдает соответствующий ему класс настроения, так и вероятность, с которой отзыв отнесен к этому классу

Сравнительный анализ ROC-кривых показал, что наилучший результат классификации тональностей имеет модель SVM

Тональность → входной признак
для анализа разрыва

АНАЛИЗ КОГНИТИВНОГО РАЗРЫВА



Модель **выявила** отзывы, где текст противоречит оценке. Это не ошибка модели, а **признак когнитивного разрыва**

ПРИМЕРЫ РАЗРЫВА

Don't buy, worst product...»

Реальный рейтинг: 4


Предсказанный: 1

Made me sad, bad skin"


Реальный рейтинг: 5

Предсказанный: 1


АНАЛИЗ СООТВЕТСТВИЯ



КАЖДЫЙ 3-й ОТЗЫВ содержит разрыв подтверждая потребительский феномен



«but» и т.п. ВДОВОЕ увеличивает риск разрыва




чем длиннее отзыв, тем выше шанс колебаний

Совпадение оценки и текста Слабый разрыв Умеренный / сильный разрыв

ПРОВЕДЕННЫЙ АНАЛИЗ & РЕЗУЛЬТАТ

Ручная проверка валидировала
алгоритм детекции

Модель количественно оценивает вклад
каждого признака в разрыв:
противоречия, длина, полярность



*комплексный анализ лингвистических признаков

MAE = 0.550; выявлено 37.5% отзывов с разрывом; определены ключевые факторы

ЗАКЛЮЧЕНИЕ

Обучили
модель классификации
тональности
(SVM, AUC = 0.965)

Разработан алгоритм
классификации
когнитивного разрыва
по силе и
направлению
(противоречия, длина
текста, полярность)

Обучили модель для
прогнозирования
рейтинга

РЕЗУЛЬТАТ МЕТРИК
МОДЕЛИ:

MAE = 0.550

RMSE = 0.800

$R^2 = 0.439$